PROGRAMACIÓN AVANZADA
ING. CIVIL PLAN COMÚN – SEDE TEMUCO

“COMPARACIÓN INTERNACIONAL DE EMISIONES DE CO_2”

Avance 2: Limpieza, tratamiento de nulos y transformación de datos con Pandas

Nº Grupo	7
Integrantes	Sebastián Quidel Daniel Retamal Luis Vázquez
Docente	Alex Eladio Flores Fuentealba
Repositorio	github.com/leufucorestaurant-prog/comparacion-internacional-emisiones
Fecha	03/11/2026
Nota	

INFORME Nº2

Características generales

Este informe amplía el Avance 1 del Proyecto Final Integrador del Grupo 7. En el avance anterior se definió el problema, se seleccionó el conjunto *CO_2 and Greenhouse Gas Emissions* de Our World in Data (OWID) y se realizó la carga inicial con Pandas. En esta etapa se construye un pipeline reproducible que diagnostica la calidad de los datos, los limpia, trata los valores nulos con una estrategia por variable, aplica transformaciones y valida el resultado antes de exportarlo a **datos/procesados/dataset_limpio.csv**. El archivo original se conserva sin modificaciones en **datos/originales/owid-co2-data.csv**, y todo el proceso se ejecuta desde la raíz con **python main.py**.

Pipeline implementado: Datos originales → Carga → Diagnóstico → Limpieza → Tratamiento de nulos → Transformaciones → Validación → Exportación. Cada etapa corresponde a una función de un módulo de **src/** y deja evidencia en **reportes/evidencias/** (tablas CSV generadas por el propio programa).

1. Diagnóstico de calidad

El diagnóstico se aplica al archivo original completo, sobre las 15 variables documentadas en el diccionario del Avance 1 (el archivo tiene 79 columnas; el resto no forma parte del análisis). La función **diagnosticar_calidad()** de **src/validaciones.py** calcula filas, columnas, tipos, nulos, porcentaje de nulos, filas duplicadas, claves país-año repetidas y valores fuera de rango, comparando cada variable con un rango válido definido en el diccionario RANGOS.

Indicador	Valor
Filas	50.411
Columnas (archivo / analizadas)	79 / 15
Valores nulos (15 variables)	319.164
Filas duplicadas	0
Claves país-año repetidas	0
Valores fuera de rango	37 (en 36 filas)
Entidades sin iso_code (agregados)	36 (7.931 filas)
Período	1750 – 2024

Tabla 1. Indicadores generales del conjunto original.

Variable	Tipo	Nulos	% nulos	Fuera de rango
country	str	0	0,00	0
year	int64	0	0,00	0
iso_code	str	7.931	15,73	0
population	float64	9.244	18,34	0
gdp	float64	35.160	69,75	0
co2	float64	21.027	41,71	0
co2_per_capita	float64	23.902	47,41	36
co2_per_gdp	float64	32.883	65,23	1
share_global_co2	float64	22.848	45,32	0
cumulative_co2	float64	22.848	45,32	0
coal_co2	float64	28.486	56,51	0
oil_co2	float64	24.952	49,50	0

Variable	Tipo	Nulos	% nulos	Fuera de rango
gas_co2	float64	32.264	64,00	0
consumption_co2	float64	45.358	89,98	0
total_ghg	float64	12.261	24,32	0

Tabla 2. Tipos, nulos y valores fuera de rango por columna (salida de diagnosticar_calidad()).

Rangos utilizados: emisiones, combustibles, PIB y acumulado ≥ 0; población ≥ 1; participación global entre 0 y 100 %; co2_per_capita entre 0 y 100 t/persona (ningún país supera ~80 t salvo eventos extraordinarios); co2_per_gdp entre 0 y 10 kg/USD (40 veces la mediana, 0,24). total_ghg no tiene mínimo porque puede ser negativo por la absorción de los bosques.

Interpretación. El conjunto no tiene filas duplicadas ni claves país-año repetidas, por lo que su estructura es consistente. El principal problema son los nulos (319.164 celdas vacías en 15 variables), concentrados en los años anteriores a 1990: consumption_co2 tiene 90 % de nulos porque solo se estima desde 1990 y gdp 69,7 % porque llega hasta 2022. Los 37 valores fuera de rango corresponden a 36 registros de co2_per_capita sobre 100 t (Sint Maarten 1950–1977, Brunei, Curazao y Qatar antes de 1977, todos territorios de muy baja población, y Kuwait 1991) y al co2_per_gdp de Kuwait 1991 (82,6 kg/USD). Solo Kuwait 1991 queda dentro del período de análisis. Además, las 7.931 filas sin iso_code son agregados (World, continentes, grupos de ingreso y versiones “(GCP)”), salvo Kosovo, que es un país sin código ISO oficial.

2. Limpieza de datos

La función **limpiar_datos()** de **src/limpieza.py** ejecuta las acciones en el orden de la tabla. Cada acción se registra con la función **registrar()**, que guarda la cantidad de filas afectadas y la justificación en **reportes/evidencias/registro_limpieza.csv**.

Acción	Filas afectadas	Justificación
Normalizar nombres de columnas (minúsculas, snake_case, sin espacios)	15 columnas	Nombres homogéneos evitan errores al referenciarlas y al renombrarlas con unidades.
Eliminar espacios al inicio, final y dobles en texto; iso_code en mayúsculas	0 cambios	Se verificó que no hay espacios sobrantes; la función queda como control ante futuras versiones del archivo.
Nombres de país con sufijo de OWID unificados	349	Sufijos como '(country)' o '(Dutch part)' no agregan información y dificultan las uniones con otras fuentes.
iso_code recuperado para Kosovo (XKX)	174	Kosovo es un país, no un agregado; sin código se eliminaría junto con las regiones.
Agregados sin iso_code (35 entidades)	7.757 (eliminadas)	World, continentes, grupos de ingreso y versiones '(GCP)' suman países que ya están en el conjunto; incluirlos duplicaría emisiones en rankings y totales.
Años fuera de 1990-2024	34.989 (eliminadas)	Antes de 1990 la cobertura es baja (41,7 % de nulos en co2) y no hay emisiones por consumo; el análisis compara 1990-2024.
Filas idénticas	0 (eliminadas)	Una fila repetida contaría dos veces las mismas emisiones.
Claves país-año repetidas	0 (eliminadas)	Cada país debe tener un solo registro por año.
co2_per_capita > 100 t (Kuwait 1991): indicadores relativos a nulo	1	Kuwait 1991 refleja los incendios petroleros de la Guerra del Golfo (365 t/persona, 82,6 kg/USD). La emisión total se conserva, pero los indicadores per cápita y por PIB se excluyen.

Acción	Filas afectadas	Justificación
Filas sin co2	126 (eliminadas)	Sin la variable principal la fila no sirve para comparar (Monaco, San Marino, Vatican, Christmas Island...). Monaco, San Marino y Vaticano se reportan dentro de Francia e Italia.

Tabla 3. Registro de limpieza (filas afectadas y justificación de cada decisión).

Categorías inconsistentes: los nombres “Micronesia (country)” y “Sint Maarten (Dutch part)” se unificaron a “Micronesia” y “Sint Maarten”. **Identificadores:** se revisó que la combinación país-año sea única (0 repetidas) y que todos los países tengan un código de 3 letras; a Kosovo se le asignó el código provisional XKX (usado por la Comisión Europea y el FMI) para no eliminarlo junto con los agregados. **Agregados:** se eliminaron 35 entidades porque suman países que ya están en el conjunto; mantenerlos duplicaría emisiones en rankings y totales. Los totales mundiales y regionales pueden recalcularse sumando países cuando se necesiten.

Valores fuera de rango: Kuwait 1991 tiene 365 t de CO_2 por persona y 82,6 kg/USD, valores reales pero explicados por los incendios petroleros de la Guerra del Golfo. No se eliminó la fila porque la emisión total ocurrió; se anularon sus indicadores per cápita y por PIB y se creó la marca **valor_atipico = True** para excluirlo de comparaciones relativas. Los demás registros fuera de rango quedaron fuera al filtrar 1990–2024.

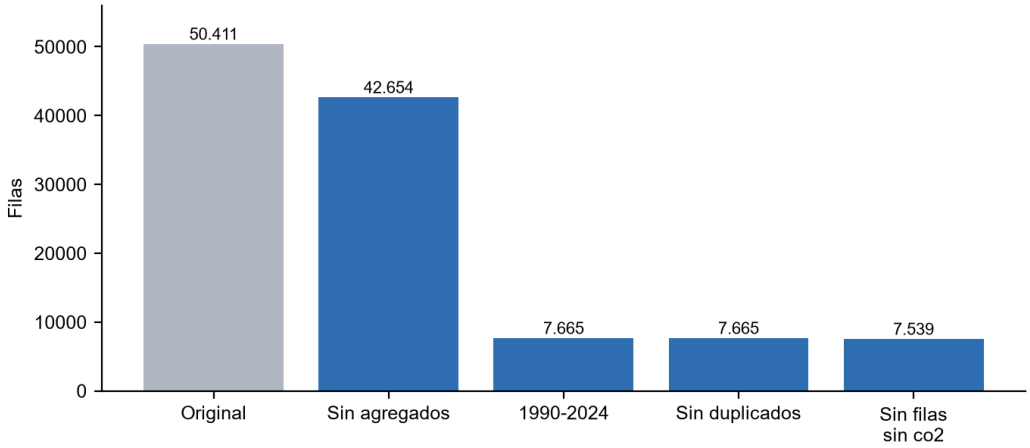


Figura 1. Cantidad de filas después de cada etapa de limpieza.

3. Tratamiento de nulos

La función **tratar_nulos()** aplica una estrategia distinta a cada variable. Los nulos iniciales se miden sobre el conjunto ya filtrado a países y años 1990–2024 (7.665 filas), es decir, después de la limpieza estructural y antes de tratar los nulos. Ninguna variable se reemplazó por cero de forma general: el cero solo se imputó en combustibles cuando se comprobó, fila a fila, que el total de co2 ya cuadra sin ese combustible.

Variable	Nulos iniciales	Estrategia	Justificación	Nulos finales
iso_code	7.931 (original) / 174 Kosovo	Recuperar desde fuente válida (Kosovo = XKX) y eliminar agregados	Un iso_code vacío marca un agregado; Kosovo es la única excepción y se recuperó su código.	0
co2	126	Eliminar registros	Es la variable principal; imputarla inventaría emisiones. 105 de las 126 filas son Mónaco, San Marino y Vaticano, cuyas emisiones OWID incluye en Francia e Italia.	0

Variable	Nulos iniciales	Estrategia	Justificación	Nulos finales
share_global_co2	126	Eliminar registros (junto con co2)	Sus nulos coinciden exactamente con las filas sin co2.	0
cumulative_co2	126	Eliminar registros (junto con co2)	Sus nulos coinciden exactamente con las filas sin co2.	0
coal_co2	2.888	Imputar 0 solo si co2 = suma de los demás componentes (2.761 filas)	El total ya cuadra sin carbón: el país no lo usa. En la única fila donde no cuadra se mantiene el nulo.	1
oil_co2	188	Imputar 0 solo si co2 = suma de los demás componentes (62 filas)	Mismo criterio; todas las filas cuadraban.	0
gas_co2	3.408	Imputar 0 solo si co2 = suma de los demás componentes (3.281 filas)	Mismo criterio; una fila no cuadra y se mantiene nula.	1
population	66	Mantener nulo (se intentó interpolar huecos internos: 0 casos)	Los nulos son Antártica e Isla de Navidad, sin población permanente registrada. El nulo tiene significado.	66
co2_per_capita	193	Recuperar como co2 / población (fuente válida: definición OWID); mantener nulo	No hubo filas recuperables: los 67 nulos son los territorios sin población y Kuwait 1991, anulado por atípico.	67
gdp	2.255	Mantener nulo	OWID publica PIB solo hasta 2022; imputar 2023–2024 sería un pronóstico. El análisis por PIB se limita a 1990–2022.	2.130
co2_per_gdp	2.257	Recuperar como co2 / PIB; mantener nulo	Sin PIB el indicador no existe; se mantiene nulo.	2.131
consumption_co2	3.601	Mantener nulo	OWID solo estima emisiones de consumo para países con tablas de comercio; nulo = “no estimado”. Variable complementaria.	3.476
total_ghg	585	Mantener nulo (interpolación de huecos internos: 0 casos)	Son territorios completos sin inventario de GEI (Groenlandia, Bermudas, etc.); no hay base para estimarlos.	585
tramo_co2_per_capita (nueva)	67	Categoría “desconocido”	Cuando no hay CO2 per cápita no se puede clasificar; se explicita en vez de dejar vacío.	0
combustible_principal (nueva)	62	Categoría “desconocido”	Países sin desglose por combustible o con emisión 0.	0

Tabla 4. Estrategia de tratamiento de nulos por variable.

Como resultado, las variables clave del análisis (país, código, año, co2, participación y acumulado) quedan sin nulos, los combustibles quedan con solo dos nulos y los nulos restantes tienen un significado documentado (sin población, sin PIB publicado, sin estimación de consumo o sin inventario de GEI).

4. Transformaciones

Las transformaciones se implementan en **src/transformaciones.py** (funciones convertir_tipos(), crear_variables() y aplicar_transformaciones()). Se aplicaron conversiones de tipo, conversión de fechas con **pd.to_datetime()**, normalización de categorías, cambio de unidades, clasificación por rangos y creación de nuevas variables.

Variable original	Transformación	Resultado	Tipo final
year	pd.to_datetime(year, format='%Y')	fecha (1990-01-01 … 2024-01-01)	datetime64
year	Extraer década: año // 10 * 10	decada (1990, 2000, 2010, 2020)	int64
population	Redondeo y conversión a entero con nulos	poblacion	Int64
population	Cambio de unidad: personas / 1.000.000	poblacion_millones	float64
country, iso_code	Normalización de nombres y conversión a categoría	pais, iso_code	category
co2_per_capita	Clasificación por rangos con pd.cut: <2, 2–5, 5–10, >10 t	tramo_co2_per_capita (+ “desconocido”)	category
iso_code	Asignación de grupo: Chile, América Latina (ARG, BRA, MEX, PER, COL), OCDE, resto	grupo_comparacion	category
gdp, population	PIB / población	pib_per_capita_usd	float64
coal_co2, co2	Participación del carbón: coal / co2 × 100	pct_carbon	float64
coal_co2, oil_co2, gas_co2	Combustible con mayor emisión (idxmax)	combustible_principal	category
co2	Variación porcentual respecto de 1990 del mismo país	variacion_co2_vs_1990_pct	float64
co2_per_capita	Marca de registro atípico (> 100 t)	valor_atipico	bool
14 variables	Renombrar con unidad explícita (co2 → co2_mt, gdp → pib_usd_ppa, total_ghg → gei_total_mt_co2e, etc.)	Nombres en español con unidad	sin cambio

Tabla 5. Transformaciones aplicadas (10 variables nuevas y 14 renombradas).

Estas variables responden directamente a los objetivos específicos del Avance 1: grupo_comparacion permite comparar a Chile con sus pares (objetivo 2), pct_carbon y combustible_principal muestran el peso del carbón (objetivo 3), variacion_co2_vs_1990_pct mide la evolución desde 1990 (objetivo 1) y valor_atipico identifica registros extremos (objetivo 4). Colombia y México, miembros de la OCDE, se clasifican como pares de América Latina para conservar la comparación regional.

5. Modularización del código

Archivo	Responsabilidad	Funciones principales
src/carga.py	Lectura y carga del conjunto	cargar_datos(), seleccionar_variables()
src/limpieza.py	Nulos, duplicados y normalización	normalizar_columnas(), eliminar_espacios(), corregir_categorias(), recuperar_identificadores(), eliminar_agregados(), filtrar_periodo(), eliminar_duplicados(), corregir_fuera_de_rango(), tratar_nulos(), limpiar_datos()
src/transformaciones.py	Conversión y creación de variables	convertir_tipos(), crear_variables(), aplicar_transformaciones()
src/validaciones.py	Comprobación de columnas, tipos y rangos	diagnosticar_calidad(), mascara_fuera_de_rango(), validar_columnas(), validar_tipos(), validar_rangos(), validar_clave_unica(), validar_sin_nulos(), validar_dataset_final()
main.py	Ejecución ordenada del pipeline	main(): carga → diagnóstico → limpieza → nulos → transformaciones → validación → exportación

Tabla 6. Distribución de responsabilidades por módulo.

main.py no contiene lógica de limpieza: solo define rutas relativas (con os.path.join), llama a las funciones de cada módulo en orden y guarda las evidencias. Si la validación falla, validar_dataset_final() lanza un error y el archivo limpio no se exporta, de modo que nunca se guarda un conjunto inválido.

```
RUTA_ORIGINAL = os.path.join("datos", "originales", "owid-co2-data.csv")
RUTA_LIMPIO = os.path.join("datos", "procesados", "dataset_limpio.csv")

def main():
    datos_originales = cargar_datos(RUTA_ORIGINAL)                    # 1. Carga
    datos = seleccionar_variables(datos_originales)
    indicadores_antes, resumen_antes = diagnosticar_calidad(          # 2. Diagnóstico
        datos[VARIABLES_ANALISIS], "conjunto original (15 variables)")
    registro = []
    datos, agregados = limpiar_datos(datos, registro)                 # 3. Limpieza
    datos, tabla_nulos = tratar_nulos(datos, registro)                # 4. Nulos
    datos, nuevas = aplicar_transformaciones(datos)                   # 5. Transformaciones
    datos = datos[COLUMNAS_FINALES]
    validar_dataset_final(datos, COLUMNAS_FINALES, TIPOS_ESPERADOS,   # 6. Validación
                          RANGOS_FINALES, clave=["pais", "anio"],
                          obligatorias=["pais", "iso_code", "anio", "co2_mt"])
    datos.to_csv(RUTA_LIMPIO, index=False, encoding="utf-8")         # 7. Exportación
```

Fragmento 1. Estructura de main.py (versión resumida; el archivo completo además imprime y guarda evidencias).

```
def tratar_nulos(datos, registro):
    ...
    for combustible in ["coal_co2", "oil_co2", "gas_co2"]:
        otros = [c for c in COMPONENTES_CO2 if c != combustible]
        suma_otros = datos[otros].sum(axis=1, min_count=1)
        cuadra = (datos["co2"] - suma_otros).abs() < 0.01
        imputar = datos[combustible].isna() & cuadra
        datos.loc[imputar, combustible] = 0.0
```

Fragmento 2. Imputación justificada de ceros en combustibles (src/limpieza.py).

6. Comparación antes y después

Indicador	Antes	Después
Filas	50.411	7.539
Columnas	15 (de 79 en el archivo)	25
Valores nulos	319.164	10.936
Filas duplicadas	0	0
Valores fuera de rango	37	0
Variables transformadas	0	14
Variables nuevas	0	10

Tabla 7. Indicadores del conjunto antes y después del pipeline.

Las filas bajan de 50.411 a 7.539 porque se eliminaron los agregados, los años anteriores a 1990 y las filas sin co2. Los nulos bajan de 319.164 a 10.936 considerando las 25 columnas finales; si se cuentan solo las 15 variables originales, quedan 8.457 nulos, todos con significado documentado. Las columnas aumentan de 15 a 25 por las 10 variables nuevas (las columnas auxiliares de cemento, quema y otras industrias solo se usaron para validar los combustibles y no se exportan).

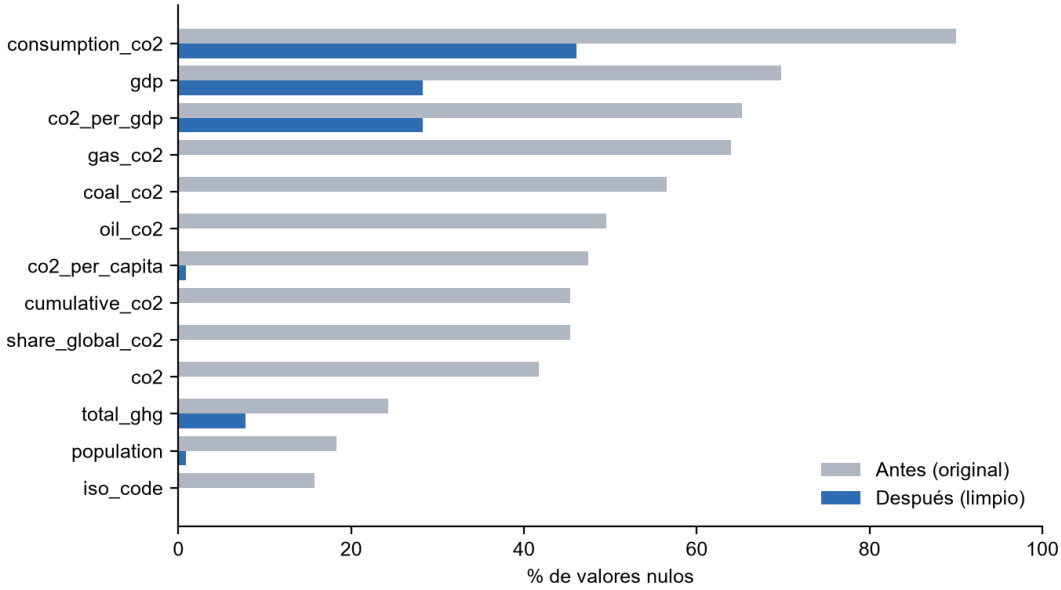


Figura 2. Porcentaje de nulos por variable antes (archivo original) y después (dataset limpio).

7. Evidencias de ejecución

Salida real obtenida al ejecutar **python main.py** desde la raíz del repositorio (Python 3.13, pandas 3.1.0). La salida completa se guarda en reportes/salida_main.txt.

```
Carga realizada: 50411 filas y 79 columnas en el archivo original.

=== Diagnóstico de calidad: conjunto original (15 variables) ===
  filas: 50411
  columnas: 15
  valores_nulos: 319164
  filas_duplicadas: 0
  claves_repetidas: 0
  valores_fuera_de_rango: 37
  filas_con_valores_fuera_de_rango: 36
```

Evidencia 1. Carga y diagnóstico inicial.

```
=== Limpieza ===
  - Limpieza: Nombres de país con sufijo de OWID unificados -> 349 filas
  - Identificadores: iso_code recuperado para Kosovo (XKX) -> 174 filas
  - Limpieza: Agregados sin iso_code (35 entidades) -> 7757 filas
  - Limpieza: Años fuera de 1990-2024 -> 34989 filas
  - Duplicados: Filas idénticas -> 0 filas
  - Duplicados: Claves país-año repetidas -> 0 filas
  - Fuera de rango: co2_per_capita > 100 t (Kuwait 1991): indicadores relativos a nulo -> 1 filas
=== Tratamiento de nulos ===
  - Nulos: Filas sin co2 -> 126 filas
  variable         iniciales  finales  estrategia
  co2                    126        0  Eliminar registros
  share_global_co2       126        0  Eliminar registros (junto con co2)
  cumulative_co2         126        0  Eliminar registros (junto con co2)
  coal_co2              2888        1  Imputar 0 si co2 = suma del resto (2761 filas)
  oil_co2                188        0  Imputar 0 si co2 = suma del resto (62 filas)
  gas_co2               3408        1  Imputar 0 si co2 = suma del resto (3281 filas)
  population              66       66  Interpolar huecos internos (0 filas); mantener nulo si el país no tiene datos
  co2_per_capita         193       67  Recalcular co2 / population donde sea posible (0 filas); resto nulo
  gdp                   2255     2130  Mantener nulo
  co2_per_gdp           2257     2131  Recalcular co2 / gdp donde sea posible (0 filas); resto nulo
  consumption_co2       3601     3476  Mantener nulo
  total_ghg              585      585  Interpolar huecos internos (0 filas); mantener nulo
```

Evidencia 2. Registro de limpieza y tabla de nulos impresa por el programa.

```
=== Transformaciones ===
  Variables nuevas (9): ['fecha', 'decada', 'poblacion_millones', 'pib_per_capita_usd', 'pct_carbon', 'combustible_...

=== Validación del conjunto final ===
  [OK] Columnas: todas presentes
  [OK] Tipos: tipos correctos
  [OK] Rangos: 0 valores fuera de rango
  [OK] Clave única: 0 claves ['pais', 'anio'] repetidas
  [OK] Obligatorias: sin nulos en variables obligatorias
Dataset limpio exportado en datos\procesados\dataset_limpio.csv (7539 filas x 25 columnas).

=== Comparación antes y después ===
              indicador  antes  despues
                  Filas  50411     7539
               Columnas     15       25
         Valores nulos 319164    10936
       Filas duplicadas      0        0
 Valores fuera de rango     37        0
Variables transformadas      0       14
       Variables nuevas      0       10
  Variables nuevas: ['fecha', 'decada', 'grupo_comparacion', 'poblacion_millones', 'pib_per_capita_usd', 'tramo_co2...
Evidencias guardadas en reportes\evidencias/
```

Evidencia 3. Transformaciones, validación final, exportación y comparación.

pais	anio	co2_mt	co2_per_capita_t	tramo_co2_per_capita	pct_carbon	variacion_co2_vs_1990_pct
Chile	1990	32.908	2.449	medio (2-5 t)	32.54	0.00
Chile	2000	58.503	3.773	medio (2-5 t)	24.34	77.78
Chile	2010	71.347	4.153	medio (2-5 t)	23.16	116.81
Chile	2022	85.744	4.385	medio (2-5 t)	23.16	160.56
Chile	2024	78.726	3.983	medio (2-5 t)	13.81	139.23

Evidencia 4. Registros de Chile en datos/procesados/dataset_limpio.csv.

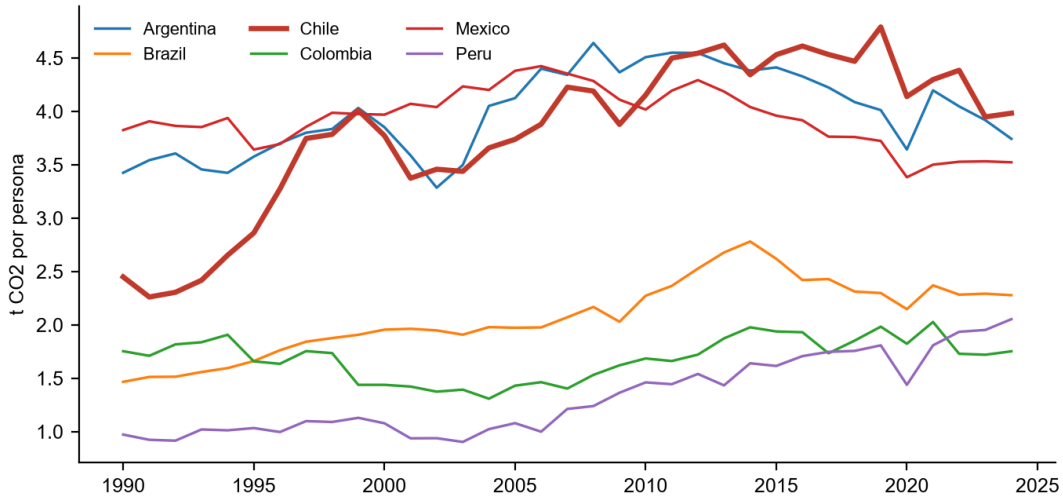


Figura 3. CO2 per cápita de Chile y sus pares latinoamericanos con el dataset limpio (comprobación de que los datos ya son utilizables).

8. Conclusión del avance

Problemas corregidos. Se separaron los países de los 35 agregados que compartían la columna country, se unificaron nombres de países con sufijos, se recuperó el código de Kosovo, se acotó el período a 1990–2024, se trató el registro extremo de Kuwait 1991 y se dejaron todas las columnas con tipos adecuados y nombres con su unidad. El conjunto final no tiene duplicados, claves repetidas ni valores fuera de rango.

Registros eliminados. 7.757 filas de agregados, 34.989 filas anteriores a 1990 y 126 filas sin emisiones de co2 (principalmente Mónaco, San Marino y Vaticano, que OWID contabiliza dentro de Francia e Italia).

No se eliminaron duplicados porque no existían. En total, de 50.411 filas quedan 7.539 (216 países, 1990–2024).

Valores imputados. Solo se imputó 0 en 6.104 celdas de combustibles (2.761 de carbón, 62 de petróleo y 3.281 de gas), y únicamente donde el co2 total coincide con la suma de los demás componentes. Además se recuperó el iso_code de Kosovo y se usó la categoría "desconocido" en dos variables categóricas. No se imputaron emisiones, población ni PIB.

Transformaciones realizadas. Conversión de year a fecha con pd.to_datetime() y extracción de la década, población a Int64 y a millones, categorías para país, código y grupos, clasificación del CO_2 per cápita en tramos, y creación de PIB per cápita, participación del carbón, combustible principal, variación respecto de 1990 y marca de atípico.

Problemas pendientes. El PIB (y co2_per_gdp) no existe para 2023–2024, por lo que las comparaciones por PIB se limitarán a 1990–2022; consumption_co2 sigue con 46 % de nulos y se usará solo como análisis complementario; las cifras de 2024 son preliminares y pueden cambiar en la próxima actualización de OWID; y los totales regionales deberán recalcularse sumando países si se necesitan.

¿Están los datos preparados para el análisis? Sí. Las variables clave (país, año, co2, participación y acumulado) no tienen nulos, la clave país-año es única, todos los valores están dentro de rango y las variables nuevas permiten responder directamente la pregunta del proyecto. Como muestra la Figura 3, el dataset limpio ya permite comparar a Chile (3,98 t por persona en 2024, 139 % más CO_2 que en 1990) con sus pares. La siguiente etapa será el análisis y la visualización de los resultados.

9. Repositorio

Enlace al repositorio actualizado: **https://github.com/leufucorestaurant-prog/comparacion-internacional-emisiones**

```
comparacion-internacional-emisiones/
├── datos/
│   ├── originales/owid-co2-data.csv      (sin modificaciones)
│   └── procesados/dataset_limpio.csv     (generado por main.py)
├── reportes/
│   ├── avance_1.pdf
│   ├── avance_2.pdf
│   ├── evidencias/   (CSV de diagnóstico, nulos, limpieza y comparación)
│   └── figuras/
├── src/
│   ├── __init__.py
│   ├── carga.py
│   ├── limpieza.py
│   ├── transformaciones.py
│   └── validaciones.py
├── README.md
├── requirements.txt
└── main.py
```

Commits del avance: "Reorganiza datos originales y estructura del proyecto", "Agrega diagnóstico inicial de calidad", "Implementa limpieza y tratamiento de valores nulos", "Incorpora transformaciones de fechas y variables", "Separa validaciones en un módulo", "Exporta dataset limpio" y "Actualiza informe del avance 2".

10. Bibliografía

Ritchie, H., Rosado, P., & Roser, M. (2023). *CO_2 and Greenhouse Gas Emissions*. Our World in Data. https://github.com/owid/co2-data (consultado el 30-10-2026).

Friedlingstein, P., et al. (2025). Global Carbon Budget 2025. *Earth System Science Data*. https://globalcarbonbudget.org

pandas development team. (2026). *pandas documentation*. https://pandas.pydata.org/docs/
International Monetary Fund. (2024). Kosovo: country code XKX. https://www.imf.org